

Roteiro de Aula 2 – Conceitos Fundamentais e Condições de Otimalidade

Disciplina: PCC179 – Otimização Não Linear

7 de outubro de 2025

1 Mínimos e Máximos Globais

Definição

Seja $f : \mathbb{R}^n \rightarrow \mathbb{R}$ uma função. Um ponto $x^* \in \mathbb{R}^n$ é dito:

- um **mínimo global** se

$$f(x^*) \leq f(x), \quad \forall x \in \mathbb{R}^n;$$

- um **máximo global** se

$$f(x^*) \geq f(x), \quad \forall x \in \mathbb{R}^n.$$

Interpretação: O ponto ótimo global é aquele que apresenta o melhor valor da função objetivo em todo o domínio — não apenas em torno de x^* , mas em qualquer ponto possível.

Exemplo geométrico

A função quadrática $f(x) = (x - 2)^2 + 1$ tem um único mínimo global em $x^* = 2$, pois $f(x) \geq 1$ para todo x .

```
import numpy as np
import matplotlib.pyplot as plt

x = np.linspace(-1, 5, 400)
f = (x - 2)**2 + 1
plt.plot(x, f)
plt.scatter(2, 1, c='red', label='Minimo global (x=2)')
plt.title("f(x) = (x-2)^2 + 1")
plt.legend()
plt.xlabel("x"); plt.ylabel("f(x)")
plt.grid(True); plt.show()
```

2 Mínimos e Máximos Locais

Definição

Um ponto x^* é um **mínimo local** de f se existir $\epsilon > 0$ tal que:

$$f(x^*) \leq f(x), \quad \forall x \in B_\epsilon(x^*),$$

onde $B_\epsilon(x^*) = \{x \in \mathbb{R}^n : \|x - x^*\| < \epsilon\}$ é a vizinhança de raio ϵ em torno de x^* .

Analogamente, x^* é um **máximo local** se:

$$f(x^*) \geq f(x), \quad \forall x \in B_\epsilon(x^*).$$

Observação

- Um ponto pode ser mínimo local, mas não global. - Em funções não convexas, geralmente há múltiplos mínimos locais.
- Se f é convexa, todo mínimo local é também global.

Exemplo Considere:

$$f(x) = x^4 - 3x^2 + 2.$$

Esta função tem dois mínimos locais e um máximo local.

```
x = np.linspace(-3, 3, 400)
f = x**4 - 3*x**2 + 2
plt.plot(x, f)
plt.title("f(x) = x^4 - 3x^2 + 2 (múltiplos mínimos locais)")
plt.xlabel("x"); plt.ylabel("f(x)")
plt.grid(True)
plt.show()
```

3 Condições de Otimalidade de Primeira Ordem

Teorema (Condição Necessária de Primeira Ordem)

Se $f : \mathbb{R}^n \rightarrow \mathbb{R}$ é diferenciável e x^* é um ponto de mínimo ou máximo local, então:

$$\nabla f(x^*) = 0.$$

Esse ponto x^* é chamado de **ponto crítico** ou **estacionário**.

Interpretação Geométrica

No ponto crítico, a taxa de variação direcional de f em qualquer direção d é zero:

$$\nabla f(x^*)^\top d = 0, \quad \forall d.$$

Ou seja, a tangente do gráfico é horizontal (em 1D) ou o gradiente é o vetor nulo (em nD).

Exemplo

Para $f(x) = x^3 - 3x$, temos:

$$f'(x) = 3x^2 - 3 = 3(x^2 - 1) \implies f'(x) = 0 \implies x = \pm 1.$$

```
x = np.linspace(-2, 2, 400)
f = x**3 - 3*x
plt.plot(x, f)
plt.axvline(0, color='k', linewidth=0.8)
plt.scatter([-1,1], [-2,2], c='red', label='Pontos criticos')
plt.legend(); plt.grid(True)
plt.title("Condicao de 1a ordem: f'(x)=0 em x = +-1")
plt.show()
```

4 Condições de Otimalidade de Segunda Ordem

Teorema (Condição Suficiente de Segunda Ordem)

Suponha que $f : \mathbb{R}^n \rightarrow \mathbb{R}$ seja duas vezes diferenciável e que $\nabla f(x^*) = 0$. Então:

- Se $\nabla^2 f(x^*)$ é definida positiva, x^* é um **mínimo local estrito**.
- Se $\nabla^2 f(x^*)$ é definida negativa, x^* é um **máximo local estrito**.
- Se $\nabla^2 f(x^*)$ é indefinida, x^* é um **ponto de sela**.

Em 1 dimensão:

$$f''(x^*) > 0 \implies \text{mínimo local}, \quad f''(x^*) < 0 \implies \text{máximo local}.$$

Exemplo

Para $f(x) = x^3 - 3x$, temos:

$$f''(x) = 6x.$$

Logo:

$$f''(-1) = -6 < 0 \implies \text{máximo local}, \quad f''(1) = 6 > 0 \implies \text{mínimo local}.$$

Visualização 2D (ponto de sela)

A função $f(x, y) = x^2 - y^2$ tem gradiente nulo em $(0, 0)$, mas Hessiana indefinida:

$$\nabla^2 f(0, 0) = \begin{bmatrix} 2 & 0 \\ 0 & -2 \end{bmatrix}.$$

Logo, $(0, 0)$ é um ponto de sela.

```
from mpl_toolkits.mplot3d import Axes3D
X, Y = np.meshgrid(np.linspace(-2,2,100), np.linspace(-2,2,100))
Z = X**2 - Y**2

fig = plt.figure()
ax = fig.add_subplot(111, projection='3d')
ax.plot_surface(X, Y, Z, cmap='coolwarm', alpha=0.8)
ax.scatter(0, 0, 0, c='k', s=40)
ax.set_title("f(x,y) = x^2 - y^2 (ponto de sela)")
plt.show()
```

5 Resumo das Condições de Otimalidade

Condição	Formulação	Interpretação
1ª Ordem (necessária)	$\nabla f(x^*) = 0$	Nenhuma direção reduz f localmente.
2ª Ordem (suficiente)	$\nabla^2 f(x^*)$ definida positiva	Mínimo local estrito.
2ª Ordem (suficiente)	$\nabla^2 f(x^*)$ definida negativa	Máximo local estrito.
Ponto de sela	$\nabla^2 f(x^*)$ indefinida	Nem mínimo nem máximo.

Tabela 1: Resumo das condições de otimalidade (problemas sem restrições).

6 Expansão em Série de Taylor

A expansão em série de Taylor é uma ferramenta fundamental em otimização, pois permite aproximar funções diferenciáveis por polinômios, revelando o comportamento local de f em torno de um ponto x^* . Essa aproximação é a base teórica das condições de otimalidade e de muitos algoritmos (como métodos de Newton).

Definição (Série de Taylor de Primeira e Segunda Ordem)

Seja $f : \mathbb{R}^n \rightarrow \mathbb{R}$ uma função com derivadas contínuas até segunda ordem. A expansão de f em torno de um ponto x^* é dada por:

$$f(x) = f(x^*) + \nabla f(x^*)^\top (x - x^*) + \frac{1}{2}(x - x^*)^\top \nabla^2 f(x^*)(x - x^*) + o(\|x - x^*\|^2),$$

onde:

- $\nabla f(x^*)$ é o **vetor gradiente** em x^* ;
- $\nabla^2 f(x^*)$ é a **matriz Hessiana** em x^* ;
- $o(\|x - x^*\|^2)$ representa termos de ordem superior que se tornam desprezíveis para x próximo de x^* .

Interpretação Geométrica

- O termo **linear** $\nabla f(x^*)^\top (x - x^*)$ representa o plano tangente de f em x^* . - O termo **quadrático** $\frac{1}{2}(x - x^*)^\top \nabla^2 f(x^*)(x - x^*)$ descreve a curvatura local. - Em 1D, temos:

$$f(x) \approx f(x^*) + f'(x^*)(x - x^*) + \frac{1}{2}f''(x^*)(x - x^*)^2.$$

Observação: A partir dessa expansão, podemos entender:

- Se o termo linear é nulo ($\nabla f(x^*) = 0$), o ponto é estacionário.
- O termo quadrático (Hessiana) determina se esse ponto é mínimo, máximo ou sela.

Exemplo Numérico (1D)

Considere $f(x) = e^x$ e $x^* = 0$. A expansão de Taylor até segunda ordem é:

$$f(x) \approx f(0) + f'(0)x + \frac{1}{2}f''(0)x^2 = 1 + x + \frac{x^2}{2}.$$

```
import numpy as np
import matplotlib.pyplot as plt

x = np.linspace(-2, 2, 400)
f = np.exp(x)
taylor = 1 + x + 0.5*x**2

plt.plot(x, f, label='f(x) = e^x')
plt.plot(x, taylor, '--', label='Aproximacao de Taylor (2a ordem)')
plt.legend(); plt.grid(True)
plt.title("Expansao de Taylor de f(x)=e^x em torno de x=0")
plt.xlabel("x"); plt.ylabel("f(x)")
plt.show()
```

Exemplo Multidimensional

Para $f(x, y) = x^2 + xy + y^2$, em torno de $(0, 0)$:

$$\nabla f(0, 0) = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \quad \nabla^2 f(0, 0) = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}.$$

Logo, a expansão até segunda ordem é:

$$f(x, y) \approx x^2 + xy + y^2.$$

Nesse caso, a função é puramente quadrática e a expansão coincide exatamente com a função original.

Resumo Intuitivo

- A série de Taylor permite **linearizar** e **aproximar** f localmente.
- Em algoritmos de otimização, essa aproximação serve para definir a direção e o tamanho do passo.
- As condições de primeira e segunda ordem derivam diretamente dessa expansão.

Referências

- Beck, A. (2017). *Introduction to Nonlinear Optimization: Theory, Algorithms, and Applications with MATLAB*, 2nd Edition. Springer.
- Nocedal, J., Wright, S. J. (2006). *Numerical Optimization*. Springer.