

Roteiro de Aula — Classificação de Matrizes via Forma Quadrática

Disciplina: PCC179/BCC405 — Otimização Não Linear

14 de outubro de 2025

1 Motivação

Em otimização não linear, a **Hessiana** $\nabla^2 f(x^*)$ em um ponto crítico x^* determina a natureza do ponto:

- positiva definida $\Rightarrow$ mínimo estrito;
- negativa definida $\Rightarrow$ máximo estrito;
- indefinida $\Rightarrow$ ponto de *sela*;
- semidefinida $\Rightarrow$ casos degenerados (análise adicional).

Isso motiva a **classificação de matrizes simétricas** reais $A \in \mathbb{R}^{n \times n}$ via o sinal da forma quadrática $q_A(x) = x^\top Ax$.

2 Forma Quadrática e Definições

Seja $A = A^\top \in \mathbb{R}^{n \times n}$. Definimos:

$$q_A(x) = x^\top Ax, \quad x \in \mathbb{R}^n.$$

- **Positiva definida (PD):** $x^\top Ax > 0$ para todo $x \neq 0$.
- **Positiva semidefinida (PSD):** $x^\top Ax \geq 0$ para todo x .
- **Negativa definida (ND):** $x^\top Ax < 0$ para todo $x \neq 0$.
- **Negativa semidefinida (NSD):** $x^\top Ax \leq 0$ para todo x .
- **Indefinida:** existem u, v tais que $u^\top Au > 0$ e $v^\top Av < 0$.

3 Critérios de Classificação

3.1 Critério dos Autovalores

1) Conceito e Cálculo

Para uma matriz simétrica $A \in \mathbb{R}^{n \times n}$, os **autovalores** λ_i e **autovetores** v_i são definidos por:

$$Av_i = \lambda_i v_i, \quad i = 1, \dots, n.$$

Os autovalores são obtidos resolvendo o **polinômio característico**:

$$\det(A - \lambda I) = 0.$$

Cada raiz λ_i representa um fator de escala associado ao autovetor v_i , indicando quanto a transformação linear A alonga ou contrai essa direção.

Métodos de cálculo. Para matrizes pequenas, pode-se resolver simbolicamente o determinante. Em prática, algoritmos numéricos (como os baseados em decomposições QR ou Jacobi) são usados, e bibliotecas como o **NumPy** oferecem funções eficientes (ex.: `np.linalg.eigvalsh` para matrizes simétricas).

- Se A é real e simétrica, todos os autovalores λ_i são reais.
- Os autovetores formam uma base ortogonal do espaço.

2) Exemplo Numérico

Considere a matriz:

$$A = \begin{bmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix}.$$

O polinômio característico é:

$$\det(A - \lambda I) = \begin{vmatrix} 2-\lambda & -1 & 0 \\ -1 & 2-\lambda & -1 \\ 0 & -1 & 2-\lambda \end{vmatrix} = (2-\lambda)[(2-\lambda)^2 - 1] - (-1)[(-1)(2-\lambda)].$$

Simplificando:

$$\det(A - \lambda I) = (2 - \lambda)^3 - 2(2 - \lambda) = (2 - \lambda)[(2 - \lambda)^2 - 2].$$

As raízes são:

$$\lambda_1 = 2, \quad \lambda_2 = 2 + \sqrt{2}, \quad \lambda_3 = 2 - \sqrt{2}.$$

Como todos $\lambda_i > 0$, concluímos que A é **positiva definida**.

3) Interpretação e Relação com a Forma Quadrática

A forma quadrática associada a uma matriz simétrica A é

$$q_A(x) = x^\top A x.$$

Ela mede como a transformação linear A atua sobre o vetor x , combinando sua direção e magnitude. A análise de $q_A(x)$ é central na classificação de pontos críticos em otimização e na determinação da curvatura local de superfícies.

Decomposição espectral. Se A é simétrica, existe uma matriz ortogonal Q e uma matriz diagonal $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$ tais que:

$$A = Q\Lambda Q^\top, \quad \text{com } Q^\top Q = I.$$

Substituindo em $q_A(x)$:

$$x^\top A x = x^\top Q\Lambda Q^\top x.$$

Definindo $y = Q^\top x$ (ou seja, uma mudança de base para o sistema de autovetores de A), temos:

$$q_A(x) = y^\top \Lambda y = \sum_{i=1}^n \lambda_i y_i^2.$$

Significado. Essa expressão mostra que, no sistema de coordenadas formado pelos autovetores de A , a forma quadrática se decompõe em uma soma de termos independentes, cada um ponderado por um autovalor λ_i :

$$q_A(x) = \lambda_1 y_1^2 + \lambda_2 y_2^2 + \dots + \lambda_n y_n^2.$$

Assim, o sinal de $q_A(x)$ depende exclusivamente dos sinais dos λ_i , pois $y_i^2 \geq 0$.

Consequência imediata.

- Se todos $\lambda_i > 0$, então $q_A(x) > 0$ para todo $x \neq 0 \Rightarrow A$ é **positiva definida**.
- Se todos $\lambda_i < 0$, então $q_A(x) < 0$ para todo $x \neq 0 \Rightarrow A$ é **negativa definida**.
- Se alguns $\lambda_i > 0$ e outros < 0 , o sinal de $q_A(x)$ varia conforme a direção $\Rightarrow A$ é **indefinida**.
- Se todos $\lambda_i \geq 0$ mas algum é zero, então $q_A(x) \geq 0 \Rightarrow A$ é **positiva semidefinida**.

Intuição geométrica. Cada autovetor v_i define um **eixo principal** da superfície descrita por $z = q_A(x)$. O autovalor correspondente λ_i controla a **curvatura** (ou “abertura”) da parábola nessa direção:

- $\lambda_i > 0$: a superfície curva para cima — direção de mínimo (vale de parabolóide).
- $\lambda_i < 0$: a superfície curva para baixo — direção de máximo (cúpula invertida).
- mistura de sinais: a superfície tem **curvatura de sela**, positiva em algumas direções e negativa em outras.

Conexão com otimização. No contexto da análise de uma função $f(x)$ em um ponto crítico x^* , a Hessiana $H = \nabla^2 f(x^*)$ desempenha o papel de A .

- Se H é positiva definida, f tem um mínimo local estrito em x^* .
- Se H é negativa definida, f tem um máximo local estrito.
- Se H é indefinida, x^* é um ponto de sela.

Assim, a classificação de matrizes via autovalores fornece uma ponte direta entre **álgebra linear** e **otimização não linear**.

3.2 Critério de Sylvester (Menores Principais)

1) Motivação

Embora o critério dos autovalores seja o mais direto numericamente, ele nem sempre é conveniente em demonstrações analíticas. O **Critério de Sylvester** fornece uma maneira puramente algébrica de verificar a definitude de uma matriz simétrica A , analisando os **determinantes dos menores principais**.

Esse método evita o cálculo explícito dos autovalores e é amplamente usado em **análise teórica**, **provas formais** e **verificação simbólica** de positividade.

2) Definição Formal

Seja $A \in \mathbb{R}^{n \times n}$ uma matriz simétrica. Definimos seus **menores principais** A_k como as submatrizes $k \times k$ obtidas pelos primeiros k elementos das linhas e colunas:

$$A_k = \begin{bmatrix} a_{11} & \dots & a_{1k} \\ \vdots & \ddots & \vdots \\ a_{k1} & \dots & a_{kk} \end{bmatrix}.$$

O determinante de cada A_k , denotado $\Delta_k = \det(A_k)$, é chamado de **menor principal de ordem k** .

O Critério de Sylvester afirma:

A positiva definida (PD) $\iff \Delta_k > 0$ para todo $k = 1, \dots, n$.

A negativa definida (ND) $\iff$ os sinais de Δ_k alternam: $\Delta_1 < 0, \Delta_2 > 0, \Delta_3 < 0$, etc.

Casos semidefinidos:

- Se todos $\Delta_k \geq 0$, A pode ser **positiva semidefinida**, mas não necessariamente (o critério não é suficiente nesse caso).
- Analogamente, Δ_k alternando em $\leq 0, \geq 0, \leq 0, \dots$ pode indicar **negativa semidefinida**.

3) Exemplo Numérico

Considere:

$$A = \begin{bmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix}.$$

Calculamos os menores principais:

$$\begin{aligned} A_1 &= [2], & \Delta_1 &= 2, \\ A_2 &= \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix}, & \Delta_2 &= (2)(2) - (-1)^2 = 3, \\ A_3 &= A, & \Delta_3 &= \det(A) = 4. \end{aligned}$$

Todos os determinantes são positivos:

$$\Delta_1 = 2 > 0, \quad \Delta_2 = 3 > 0, \quad \Delta_3 = 4 > 0.$$

Portanto, pelo Critério de Sylvester, A é **positiva definida**. Esse resultado coincide com a classificação obtida via autovalores.

4) Por que o Critério de Sylvester funciona

A ideia central vem da decomposição de Cholesky: uma matriz simétrica A é positiva definida se, e somente se, ela pode ser escrita como

$$A = LL^T,$$

onde L é triangular inferior com diagonais positivas.

Durante o processo de fatoração, cada $\Delta_k = \det(A_k)$ representa o produto dos quadrados dos primeiros k elementos diagonais de L :

$$\Delta_k = (l_{11}l_{22} \cdots l_{kk})^2.$$

Portanto:

$$\Delta_k > 0 \quad \forall k \iff l_{ii} > 0 \quad \forall i \iff A = LL^T \text{ com } L \text{ não singular.}$$

Assim, o sinal dos menores principais reflete diretamente a **positividade das curvaturas parciais** da forma quadrática $x^T Ax$, medida ao longo das primeiras k direções coordenadas.

Interpretação geométrica: Cada Δ_k corresponde ao “volume” (ou *determinante*) da elipsóide definida pela restrição de A ao subespaço gerado pelas primeiras k variáveis. Se algum $\Delta_k \leq 0$, significa que a forma quadrática não é positiva em todas as direções desse subespaço — indicando perda de convexidade parcial.

5) Comparativo com o critério dos autovalores

- Ambos caracterizam positividade, mas o de Sylvester evita cálculo espectral.
- O de autovalores é mais direto computacionalmente (usado em prática).
- O de Sylvester é mais prático em demonstrações analíticas e provas simbólicas.

Critério	Base teórica	Informação usada	Vantagens	Limitações
Autovalores	Decomposição espectral $A = Q\Lambda Q^T$	Sinais dos autovalores λ_i	Interpretação geométrica direta; base para classificação via Hessiana	Requer cálculo espectral; mais pesado simbolicamente
Sylvester	Menores principais $\det(A_k)$	Determinantes dos subbloco- cos superiores	Algébrico e simbólico; ideal em provas analíticas	Não conclusivo em casos semidefinidos
Cholesky	Fatoração $A = LL^T$	Elementos diagonais de L	Computacionalmente eficiente; confirma positividade direta	Apenas aplicável se A for positiva definida

Tabela 1: Comparativo entre os critérios de classificação de matrizes simétricas.

Síntese dos Critérios de Classificação

A Tabela 1 resume as principais características dos três critérios mais utilizados para determinar a definitude de uma matriz simétrica: o dos autovalores, o de Sylvester e o baseado na fatoração de Cholesky.

Resumo. Os três critérios são equivalentes para matrizes positivas definidas, mas diferem em propósito:

- **Autovalores:** fornece interpretação geométrica e ligação direta com curvatura e Hessianas;
- **Sylvester:** útil para demonstrações formais e verificação simbólica;
- **Cholesky:** preferido em implementações numéricas e verificação computacional.

4 Exemplo Numérico (3×3)

Considere

$$A = \begin{bmatrix} 4 & 1 & -1 \\ 1 & 3 & 0 \\ -1 & 0 & 2 \end{bmatrix}.$$

Podemos (i) computar autovalores para classificar, (ii) visualizar $q_A(x) = x^T A x$ em $\mathbb{R}^2$ fixando $x = (u, v, 0)$, e (iii) aplicar Sylvester.

5 Exemplo prático em Python (autovalores, Sylvester e gráfico 3D)

O código abaixo:

1. classifica A via autovalores com tolerância numérica;
2. reporta menores principais (Sylvester);
3. plota $z = [u, v, 0]^T A [u, v, 0]$ em uma malha 2D (gráfico 3D) para intuição geométrica.

```
import numpy as np
import matplotlib.pyplot as plt
from mpl_toolkits.mplot3d import Axes3D # noqa: F401 (ensures 3D projection is registered)

# --- Matrix (3x3) ---
A = np.array([[4.0, 1.0, -1.0],
              [1.0, 3.0, 0.0],
              [-1.0, 0.0, 2.0]])

# --- Classification via eigenvalues ---
def classify_definiteness(A, tol=1e-10):
    lam = np.linalg.eigvalsh(A) # symmetric eigenvalues
    pos = np.all(lam > tol)
    nonneg = np.all(lam >= -tol)
    neg = np.all(lam < -tol)
    nonpos = np.all(lam <= tol)
    if pos:
        return "Positiva definida (PD)", lam
    if nonneg and not pos:
        return "Positiva semidefinida (PSD)", lam
    if neg:
        return "Negativa definida (ND)", lam
    if nonpos and not neg:
        return "Negativa semidefinida (NSD)", lam
    return "Indefinida", lam

label, eigvals = classify_definiteness(A)
print("Classificacao:", label)
print("Autovalores :", eigvals)

# --- Sylvester: leading principal minors ---
def leading_principal_minors(A):
    dets = []
    for k in range(1, A.shape[0]+1):
```

```

        dets.append(np.linalg.det(A[:k, :k]))
    return dets

dets = leading_principal_minors(A)
print("Menores principais (det A_k):", dets)

# ---- 3D plot of z = x^T A x with x=(u,v,0) ----
u = np.linspace(-2.5, 2.5, 200)
v = np.linspace(-2.5, 2.5, 200)
U, V = np.meshgrid(u, v)

# x = [u, v, 0]; z = [u,v,0]^T A [u,v,0]
Z = (A[0,0]*U**2 + 2*A[0,1]*U*V + A[1,1]*V**2) # terms with the third comp zero
# Cross terms with third coord vanish because x3=0

fig = plt.figure(figsize=(7,5))
ax = fig.add_subplot(111, projection='3d')
ax.plot_surface(U, V, Z, alpha=0.7, linewidth=0, antialiased=True)
ax.set_xlabel('u')
ax.set_ylabel('v')
ax.set_zlabel('z = x^T A x (x3=0)')
ax.set_title(f"Forma quadrática (x3=0) --- {label}")
plt.tight_layout()
plt.show()

```

Observação. Para visualizar cortes diferentes, altere a projeção (ex.: $x = (u, 0, w)$ ou $x = (0, v, w)$) trocando os índices correspondentes na expressão de Z .

6 Resumo (tabela de bolso)

Classe	Sinal de $x^T A x$	Autovalores (simétrica)	Crítério de Sylvester (ment. principais)
PD	> 0 para $x \neq 0$	todos > 0	$\det(A_k) > 0, \forall k$
PSD	≥ 0	todos ≥ 0	não conclusivo isoladamente (ver autovalores)
ND	< 0 para $x \neq 0$	todos < 0	sinais alternados: $-, +, -, \dots$
NSD	≤ 0	todos ≤ 0	não conclusivo isoladamente (ver autovalores)
Indefinida	sinais opostos	autovalores de sinais mistos	n/a

Tabela 2: Classificação de matrizes simétricas via forma quadrática.

7 Dicas Práticas

- Em cálculo computacional, use tolerância ($\sim 10^{-10}$) ao decidir sinais de autovalores.
- Para Hessianas, prefira autovalores (via `eigvalsh`); Sylvester é útil para prova analítica.
- Em otimização, a definitude da Hessiana no ótimo influencia a taxa de convergência (Newton/quasi-Newton).