

Objetivos de Aprendizagem

Ao final desta aula, o(a) estudante deverá ser capaz de:

- Diferenciar conceitualmente métodos diretos e indiretos de otimização.
- Descrever a ideia básica de métodos aleatórios de busca direta:
 - Random Jumping;
 - Random Walk;
 - Random Walk with Direction Exploitation;
 - Grid Search.
- Aplicar e analisar, em exemplos numéricos simples:
 - o método univariado (*univariate search*);
 - o método de Powell (pattern search / direções conjugadas);
 - o método do simplex de Nelder–Mead.

Leitura Recomendada

- Kalyanmoy Deb (ou Rao): capítulo sobre *Direct Search Methods* (seção de métodos aleatórios, método univariado, Powell e simplex).

1 Introdução: Métodos Diretos vs. Indiretos

1.1 Motivação Geral

Em problemas de otimização não linear, podemos agrupar os algoritmos em duas grandes famílias:

Métodos indiretos (baseados em derivadas) utilizam explicitamente informações de derivadas da função objetivo:

- gradiente $\nabla f(\mathbf{x})$;
- Hessiana $\nabla^2 f(\mathbf{x})$ ou aproximações.

Exemplos: método do gradiente, Newton, quasi-Newton, gradiente conjugado.

Métodos diretos (sem derivadas) utilizam apenas valores da função $f(\mathbf{x})$, sem exigir derivadas analíticas ou numéricas. Exemplos: métodos aleatórios de busca, método univariado, Powell, simplex de Nelder–Mead.

Contextos em que métodos diretos são particularmente úteis:

- Funções objetivo *caixa-preta*, oriundas de simulações complexas;
- Funções não diferenciáveis, com descontinuidades ou ruído numérico;
- Situações em que derivadas são caras ou difíceis de obter e/ou implementar.

Contraste importante para enfatizar em sala:

- Métodos indiretos tendem a ser mais eficientes quando derivadas são confiáveis;
- Métodos diretos tendem a ser mais **robustos** e mais gerais, porém normalmente exigem mais avaliações de f .

2 Visão Geral: Métodos Aleatórios e Grid Search

Nesta seção, a ideia é apenas dar a *intuição* dos métodos, sem entrar em detalhes de implementação.

2.1 Random Jumping Method

Ideia Básica

- Suponha um problema irrestrito, mas com limites estabelecidos para cada variável:

$$l_i \leq x_i \leq u_i, \quad i = 1, 2, \dots, n.$$

- Geramos vetores aleatórios $\mathbf{r} = (r_1, \dots, r_n)^T$ com $r_i \sim U(0, 1)$.
- Construímos pontos no hipercubo:

$$x_i = l_i + r_i(u_i - l_i), \quad i = 1, \dots, n.$$

- Avaliamos $f(\mathbf{x})$ em cada ponto e mantemos o melhor valor encontrado.

Comentários:

- Método extremamente simples e fácil de programar;
- Adequado como **exploração inicial** do espaço de busca;
- Desvantagem: pode precisar de muitas amostras aleatórias para localizar bons mínimos em alta dimensão.

2.2 Random Walk Method

Ideia Básica

- Em vez de escolher pontos independentes, construímos uma trajetória:

$$\mathbf{X}_{i+1} = \mathbf{X}_i + \lambda \mathbf{u}_i,$$

onde:

- λ é um comprimento de passo (step length);
- $\mathbf{u}_i$ é um vetor unitário aleatório.
- Se $f(\mathbf{X}_{i+1}) < f(\mathbf{X}_i)$, aceitamos o novo ponto;
- Caso contrário, geramos uma nova direção aleatória.
- Quando não há melhorias após muitas tentativas, reduzimos λ (por exemplo, $\lambda \leftarrow \lambda/2$).

Observações:

- Usa-se um critério geométrico para evitar viés para as diagonais do hipercubo (aceita-se apenas vetores aleatórios com comprimento $R \leq 1$ antes da normalização);
- O método “caminha” pelo espaço, explorando regiões de menor valor de f .

2.3 Random Walk com Exploração de Direção

Motivação

Se uma direção aleatória $\mathbf{u}_i$ reduziu o valor de f , faz sentido aproveitar ao máximo essa direção, em vez de dar apenas um passo de comprimento fixo.

Ideia

- A partir de $\mathbf{X}_i$, fazemos uma minimização unidimensional ao longo de $\mathbf{u}_i$:

$$\mathbf{X}_{i+1} = \mathbf{X}_i + \lambda_i^* \mathbf{u}_i,$$

com

$$\lambda_i^* = \arg \min_{\lambda} f(\mathbf{X}_i + \lambda \mathbf{u}_i).$$

- Para encontrar λ_i^* , emprega-se um dos métodos unidimensionais vistos anteriormente (seção áurea, interpolação quadrática etc.).

2.4 Grid Search

Ideia Básica

- Discretizamos cada intervalo $[l_i, u_i]$ em p_i pontos:

$$x_i^{(1)}, x_i^{(2)}, \dots, x_i^{(p_i)}, \quad i = 1, \dots, n.$$

- Construímos a grade cartesiana com $p_1 p_2 \cdots p_n$ pontos;
- Avaliamos f em todos os pontos da grade;
- Escolhemos o ponto de menor valor de f como solução aproximada.

Comentários:

- Simples e determinístico;
- Sofre com a explosão combinatória em alta dimensão (ex.: $n = 10$, $p_i = 4$ leva a 4^{10} pontos);
- Útil para:
 - problemas de baixa dimensão;
 - geração de bons pontos iniciais para métodos mais sofisticados.

3 Método Univariado (Univariate Search)

3.1 Ideia Geral

No método univariado, otimizamos uma variável de cada vez, mantendo as demais fixas.

- Em cada iteração, escolhemos uma direção coordenada S_i (vetor da base canônica);
- Fazemos uma busca unidimensional ao longo dessa direção;
- Ao final de n buscas (uma por coordenada), completa-se um ciclo.

As direções típicas são:

$$S_1 = (1, 0, 0, \dots, 0)^T, \quad S_2 = (0, 1, 0, \dots, 0)^T, \quad \dots, \quad S_n = (0, 0, \dots, 1)^T.$$

3.2 Algoritmo Esquemático

1. Escolher um ponto inicial $\mathbf{X}_1$ e um *probe* pequeno ε (por exemplo, $\varepsilon = 0,01$).
2. Para cada direção S_i :

(a) Calcular $f(\mathbf{X}_k)$, $f(\mathbf{X}_k + \varepsilon S_i)$ e $f(\mathbf{X}_k - \varepsilon S_i)$;

(b) Determinar a direção de descida:

- se $f(\mathbf{X}_k + \varepsilon S_i) < f(\mathbf{X}_k)$, usar $+S_i$;
- se $f(\mathbf{X}_k - \varepsilon S_i) < f(\mathbf{X}_k)$, usar $-S_i$;
- se nenhuma reduz f , considerar que não há melhora naquela coordenada.

(c) Se houver direção de descida, resolver

$$\min_{\lambda} f(\mathbf{X}_k \pm \lambda S_i)$$

com um método unidimensional adequado e obter λ_i^* .

(d) Atualizar:

$$\mathbf{X}_{k+1} = \mathbf{X}_k \pm \lambda_i^* S_i.$$

3. Repetir ciclos sobre as n direções até que a melhoria em f seja pequena.

3.3 Exemplo Numérico

Considere a função

$$f(x_1, x_2) = x_1 - x_2 + 2x_1^2 + 2x_1x_2 + x_2^2,$$

e o ponto inicial

$$\mathbf{X}_1 = (0, 0)^T.$$

Iteração 1: direção $S_1 = (1, 0)^T$

- $f(0, 0) = 0$;
- $f(\varepsilon, 0) = \varepsilon + 2\varepsilon^2$; para $\varepsilon = 0,01$,

$$f(0,01, 0) \approx 0,0102;$$

- $f(-\varepsilon, 0) = -\varepsilon + 2\varepsilon^2$;

$$f(-0,01, 0) \approx -0,0098.$$

Como $f(-\varepsilon, 0) < f(0, 0)$, a direção de descida é $-S_1$.

Agora minimizamos $f(-\lambda, 0) = 2\lambda^2 - \lambda$. Derivando:

$$\frac{d}{d\lambda}(2\lambda^2 - \lambda) = 4\lambda - 1 = 0 \Rightarrow \lambda^* = \frac{1}{4}.$$

Logo, o novo ponto é

$$\mathbf{X}_2 = \mathbf{X}_1 - \lambda^* S_1 = \left(-\frac{1}{4}, 0\right)^T,$$

com

$$f\left(-\frac{1}{4}, 0\right) = -\frac{1}{8}.$$

Iteração 2: direção $S_2 = (0, 1)^T$

A partir de $\mathbf{X}_2 = (-1/4, 0)$, repete-se o procedimento:

- calcula-se $f(-1/4, 0)$, $f(-1/4, \varepsilon)$ e $f(-1/4, -\varepsilon)$;
- determina-se se a direção correta é $+S_2$ ou $-S_2$;
- realiza-se a minimização unidimensional $f(-1/4, \lambda)$ para encontrar λ^* ;
- obtém-se o novo ponto $\mathbf{X}_3$.

Comentário didático: é interessante realizar pelo menos um ciclo completo no quadro, mostrando a trajetória aproximada e discutindo:

- lentidão perto do ótimo;
- possibilidade de travamento em vales estreitos (exemplo com falha do univariate em um vale muito “fino”).

4 Método de Powell (Pattern Search / Direções Conjugadas)

4.1 Intuição

Problema do método univariado:

- As direções de busca são sempre paralelas aos eixos de coordenadas;
- Perto do mínimo, isso gera uma trajetória “dente de serra” e convergência lenta;
- Em funções com vales alongados, o método pode oscilar muito.

Ideia de Powell:

- Observar que, para funções quadráticas em duas variáveis, as retas que ligam pontos alternados do método univariado tendem a passar pelo mínimo;
- Usar essas retas como novas direções de busca, chamadas **direções padrão** ou **direções conjugadas**;
- Em funções quadráticas de n variáveis, um conjunto de n direções *conjugadas* permite atingir o mínimo em no máximo n passos de minimização unidimensional (convergência quadrática).

4.2 Ideia de Direções Conjugadas

Seja A uma matriz simétrica $n \times n$ (por exemplo, a Hessiana de uma função quadrática). Um conjunto de vetores $S_1, \dots, S_n$ é **A -conjugado** se

$$S_i^T A S_j = 0, \quad \text{para } i \neq j.$$

Direções ortogonais (no sentido usual) são um caso particular, quando $A = I$.

4.3 Esboço do Algoritmo de Powell

Para um problema em n variáveis:

1. Escolher ponto inicial $\mathbf{X}_1$.
2. Inicializar as direções $S_1, \dots, S_n$ como os vetores coordenados.
3. **Para cada ciclo:**
 - (a) Guardar o ponto inicial do ciclo: $Z = X$.
 - (b) Para $i = 1, \dots, n$:
 - Minimizar f ao longo de S_i a partir de X ;
 - Atualizar o ponto X com o resultado da minimização unidimensional.
 - (c) Ao final do ciclo, construir a **direção padrão**:
$$S_p = X - Z.$$
 - (d) Minimizar f ao longo de S_p , atualizando novamente X .
 - (e) Atualizar o conjunto de direções substituindo a *mais antiga* por S_p .
4. Repetir ciclos até que a melhoria em f seja pequena.

4.4 Exemplo Numérico (Esboço)

Usando novamente

$$f(x_1, x_2) = x_1 - x_2 + 2x_1^2 + 2x_1x_2 + x_2^2,$$

e ponto inicial $\mathbf{X}_1 = (0, 0)$:

- Primeiramente, execute um ciclo de busca univariada ao longo de S_1 e S_2 para obter um ponto X_4 ;
- Defina $S_p = X_4 - X_1$;
- Faça uma busca unidimensional ao longo de S_p ;
- Mostre (em quadro) que, neste exemplo quadrático, o ponto ótimo é atingido rapidamente.

Mensagem didática:

- Powell é um método direto eficiente para funções suaves;
- Para funções quadráticas, é teoricamente quadraticamente convergente;
- Em funções gerais, continua sendo útil, embora sem as garantias exatas de convergência em n ciclos.

5 Método do Simplex (Nelder–Mead)

5.1 Visão Geométrica

Definição de simplex:

- Em $\mathbb{R}^n$, um **simplex** é o envelope convexo de $n + 1$ pontos não coplanares;
- Para $n = 1$, é um segmento de reta (2 pontos);
- Para $n = 2$, é um triângulo (3 pontos);
- Para $n = 3$, é um tetraedro (4 pontos), etc.

No método de Nelder–Mead:

- Mantém-se um simplex a cada iteração;
- Em cada passo, avalia-se f nos vértices;
- Movimenta-se o simplex via:
 - **Reflexão** do pior vértice;
 - **Expansão**, se a reflexão produziu um valor muito bom;
 - **Contração**, se a reflexão não foi boa;
 - **Encolhimento** (*shrink*), se mesmo a contração falhar.

5.2 Passos Básicos em 2D (Triângulo)

Considere $n = 2$ (didaticamente mais simples):

1. Iniciar com três pontos X_1, X_2, X_3 e calcular $f(X_i)$.
2. Identificar:
 - X_l : ponto com menor valor f (melhor);
 - X_h : ponto com maior valor f (pior);
 - X_m : ponto intermediário.
3. Calcular o centroide dos vértices exceto o pior:

$$X_0 = \frac{1}{n} \sum_{i \neq h} X_i.$$

4. **Reflexão**:

$$X_r = X_0 + \alpha(X_0 - X_h), \quad \alpha > 0.$$

5. Avaliar $f(X_r)$ e aplicar a regra:

- Se $f(X_l) \leq f(X_r) < f(X_m)$, substituir X_h por X_r e seguir para a próxima iteração;
- Se $f(X_r) < f(X_l)$, tentar **expansão**;
- Se $f(X_r) \geq f(X_m)$, tentar **contração**.

6. **Expansão** (se X_r for muito bom):

$$X_e = X_0 + \gamma(X_r - X_0), \quad \gamma > 1.$$

Escolher entre X_r e X_e o ponto com menor valor para substituir X_h .

7. **Contração**: se reflexão foi ruim:

$$X_c = X_0 + \beta(X_h - X_0), \quad 0 < \beta < 1.$$

Se $f(X_c)$ melhorar o simplex, substituir X_h por X_c . Caso contrário, realizar **encolhimento**:

$$X_i \leftarrow \frac{X_i + X_l}{2}, \quad \text{para todos os vértices } i.$$

5.3 Exemplo Numérico Esquemático

Considere novamente

$$f(x_1, x_2) = x_1 - x_2 + 2x_1^2 + 2x_1x_2 + x_2^2,$$

e um simplex inicial com:

$$X_1 = (4, 4), \quad X_2 = (5, 4), \quad X_3 = (4, 5).$$

Sugestão para a aula:

1. Calcular $f(X_1), f(X_2), f(X_3)$;
2. Identificar X_l, X_m, X_h ;
3. Calcular X_0 e construir X_r ;
4. Verificar se é caso de expansão ou não;
5. Desenhar o triângulo original e o triângulo após a operação em um gráfico de contorno (mesmo qualitativo).

5.4 Comentários Finais sobre o Simplex de Nelder–Mead

- Método direto popular em baixa dimensão;
- Não usa derivadas, é puramente geométrico;
- Funciona bem em muitas aplicações práticas, mas não tem garantias fortes de convergência global;
- Em dimensões mais altas, o comportamento pode se deteriorar (necessidade de muitas avaliações de f e geometria do simplex pode ficar pobre).

Resumo e Pontos para Fixação

- **Métodos diretos** são apropriados quando derivadas são indisponíveis, não confiáveis ou muito caras.
- Métodos simples como **Random Jumping**, **Random Walk** e **Grid Search** são úteis para explorar o espaço e encontrar regiões promissoras.
- O **método univariado** é conceitualmente simples, mas pode ser lento e sofrer com vales estreitos.
- O **método de Powell** explora direções padrão (aproximadamente conjugadas) para acelerar a convergência em funções suaves, especialmente quadráticas.
- O **método do simplex (Nelder–Mead)** usa operações geométricas (reflexão, expansão, contração, encolhimento) sobre um simplex para aproximar o mínimo.

Sugestões de Exercícios

1. Implementar o método univariado para a função

$$f(x_1, x_2) = x_1 - x_2 + 2x_1^2 + 2x_1x_2 + x_2^2$$

e comparar a trajetória com um método de gradiente.

2. Implementar o método de Powell em duas dimensões e testar em:
 - uma função quadrática;
 - uma função não quadrática com vale alongado.
3. Implementar o método do simplex de Nelder–Mead em 2D, reproduzindo pelo menos duas iterações completas (com reflexão e alguma combinação de expansão/contração).
4. Investigar numericamente o efeito da escolha dos parâmetros α , β e γ no comportamento do método do simplex.