

Roteiro de Aula
Otimização Não Linear
Métodos de Busca Indireta (Descent Methods)

Prof. Rodrigo Silva

Objetivos da aula

Ao final desta aula, o estudante deverá ser capaz de:

- Definir o **gradiente** de uma função $f : \mathbb{R}^n \rightarrow \mathbb{R}$ e interpretar seu significado geométrico.
- Explicar por que o gradiente é a **direção de máximo crescimento** (steepest ascent) e $-\nabla f$ é a direção de **máxima descida**.
- Discutir dificuldades práticas na **avaliação do gradiente** e aplicar **diferenças finitas** para aproximá-lo.
- Calcular a **taxa de variação de f ao longo de uma direção S_i** :

$$\frac{df}{d\lambda} = \nabla f^\top S_i.$$

- Descrever e aplicar o **método do declive máximo** (steepest descent / método de Cauchy) em um exemplo simples.
- Apresentar e interpretar **critérios de parada** em métodos iterativos de otimização irrestrita.

Baseado em RAO, Singiresu S. *Engineering Optimization: Theory and Practice*. 5. ed. Hoboken: John Wiley and Sons, 2020.

1 Contextualização

- Problema geral de **minimização irrestrita**:

$$\min_{X \in \mathbb{R}^n} f(X).$$

- Nas aulas anteriores foram estudados métodos de **busca direta** (sem derivadas).
- Motivação para **métodos de busca indireta (descent methods)**:
 - Usar informação de derivada para escolher direções de busca mais eficientes.
 - Em problemas suaves, espera-se convergência mais rápida comparada a métodos puramente heurísticos.

2 Gradiente de uma função

2.1 Definição

Seja $f : \mathbb{R}^n \rightarrow \mathbb{R}$ uma função escalar diferenciável. O **gradiente** de f em $X = (x_1, \dots, x_n)^\top$ é o vetor coluna

$$\nabla f(X) = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \\ \vdots \\ \frac{\partial f}{\partial x_n} \end{bmatrix}.$$

- $\nabla f(X)$ aponta, localmente, na direção em que f cresce mais rapidamente.
- Geometricamente, em $\mathbb{R}^2$, o gradiente é ortogonal às curvas de nível de f .

2.2 Intuição geométrica: direção de máxima inclinação

- Em $n = 2$, imagine $f(x_1, x_2)$ como uma superfície.
- As curvas de nível $f(x_1, x_2) = c$ são linhas no plano (x_1, x_2) .
- O gradiente ∇f é perpendicular a essas curvas de nível e aponta para valores maiores de f .
- Consequentemente, $-\nabla f$ aponta para a direção de maior **decréscimo** de f .

2.3 Teorema 6.3: o gradiente como direção de steepest ascent

Teorema 6.3. O vetor gradiente $\nabla f(X)$ representa a direção de **máxima taxa de crescimento** (steepest ascent) da função f no ponto X .

Ideia da demonstração

Considere um ponto arbitrário X e um ponto vizinho $X + dX$ com

$$dX = \begin{bmatrix} dx_1 \\ dx_2 \\ \vdots \\ dx_n \end{bmatrix}.$$

(a) O comprimento do vetor dX é

$$(ds)^2 = dX^\top dX = \sum_{i=1}^n (dx_i)^2.$$

(b) A variação de f é dada por

$$df = \sum_{i=1}^n \frac{\partial f}{\partial x_i} dx_i = \nabla f^\top dX.$$

(c) Escrevemos $dX = u ds$, onde u é um vetor unitário ($\|u\| = 1$) que indica a direção do passo.

(d) Então,

$$\frac{df}{ds} = \nabla f^\top u.$$

(e) Usando o produto interno, obtemos

$$\frac{df}{ds} = \|\nabla f\| \|u\| \cos \theta = \|\nabla f\| \cos \theta,$$

onde θ é o ângulo entre ∇f e u .

(f) Como $\cos \theta \leq 1$, a taxa de variação $\frac{df}{ds}$ é máxima quando $\theta = 0^\circ$, isto é, quando u está alinhado com ∇f .

2.4 Teorema 6.4: valor máximo da taxa de mudança

Teorema 6.4. A taxa máxima de variação de f em um ponto X é igual à norma do gradiente nesse ponto:

$$\left(\frac{df}{ds} \right)_{\max} = \|\nabla f(X)\|.$$

Isso decorre diretamente da expressão

$$\frac{df}{ds} = \|\nabla f\| \cos \theta,$$

que atinge seu máximo em $\cos \theta = 1$.

Observação: se o gradiente é a direção de máximo crescimento, então $-\nabla f$ é a direção de **máximo decréscimo** (steepest descent).

3 Avaliação do gradiente na prática

3.1 Situações típicas problemáticas

A avaliação de ∇f pode ser problemática em três situações:

1. f é diferenciável, mas é impraticável ou impossível derivar as expressões analíticas de $\frac{\partial f}{\partial x_i}$.
2. As expressões analíticas existem, mas são muito complexas e caras de avaliar (alto custo computacional).
3. O gradiente não é definido em todos os pontos (função não diferenciável em certos pontos).

Nas situações (1) e (2), frequentemente se usam **diferenças finitas**. Na situação (3), o uso de diferenças finitas pode levar à quebra do algoritmo; métodos de busca direta são mais adequados.

3.2 Diferenças finitas progressivas (forward difference)

Para aproximar a derivada parcial em X_m :

$$\left. \frac{\partial f}{\partial x_i} \right|_{X_m} \approx \frac{f(X_m + \Delta x_i u_i) - f(X_m)}{\Delta x_i},$$

onde:

- Δx_i é um pequeno incremento na coordenada x_i ;
- u_i é o vetor canônico com 1 na posição i e 0 nas demais.

Se $f(X_m)$ já for conhecido, essa aproximação requer apenas **uma avaliação adicional** de f por componente. O gradiente completo em $\mathbb{R}^n$ requer n avaliações adicionais de f .

3.3 Diferenças finitas centrais (central difference)

Uma aproximação mais precisa é dada por:

$$\left. \frac{\partial f}{\partial x_i} \right|_{X_m} \approx \frac{f(X_m + \Delta x_i u_i) - f(X_m - \Delta x_i u_i)}{2\Delta x_i}.$$

Nesse caso, são necessárias **duas avaliações** de f por componente, em troca de maior precisão.

3.4 Escolha de Δx_i : erros de arredondamento e truncamento

- Se Δx_i é **muito pequeno**, os valores de f em $X_m \pm \Delta x_i u_i$ são muito próximos e o erro de arredondamento pode dominar.
- Se Δx_i é **muito grande**, perde-se a localidade da aproximação e o erro de truncamento aumenta.
- Na prática, escolhe-se Δx_i de acordo com a escala de x_i e a precisão numérica disponível.

3.5 Gradiente não definido em todos os pontos

Quando f possui descontinuidades na derivada (quinas), a derivada pode não existir em certos pontos. Nesses casos:

- Diferentes valores de Δx_i podem produzir inclinações diferentes ao aplicar fórmulas de diferença finita.
- Isso é um indicativo de que a derivada não existe naquele ponto.
- Métodos baseados em gradiente podem falhar; é preferível usar métodos de busca direta.

4 Taxa de variação ao longo de uma direção

Em muitos métodos de otimização, escolhemos uma direção de busca S_i e realizamos uma **busca unidirecional** em λ .

4.1 Parametrização ao longo de S_i

Dado um ponto X_i e uma direção S_i , qualquer ponto sobre a reta é da forma

$$X(\lambda) = X_i + \lambda S_i.$$

Definimos uma função escalar de uma variável:

$$\varphi(\lambda) = f(X_i + \lambda S_i).$$

4.2 Derivada direcional: $\frac{df}{d\lambda} = \nabla f^\top S_i$

Pela regra da cadeia:

$$\frac{df}{d\lambda} = \sum_{j=1}^n \frac{\partial f}{\partial x_j} \frac{\partial x_j}{\partial \lambda}.$$

Como $x_j(\lambda) = x_{ij} + \lambda s_{ij}$, temos $\frac{\partial x_j}{\partial \lambda} = s_{ij}$. Logo,

$$\frac{df}{d\lambda} = \sum_{j=1}^n \frac{\partial f}{\partial x_j} s_{ij} = \nabla f^\top S_i.$$

Se λ^* minimiza $\varphi(\lambda)$, então

$$\left. \frac{df}{d\lambda} \right|_{\lambda=\lambda^*} = 0 \quad \Rightarrow \quad \nabla f(X_i + \lambda^* S_i)^\top S_i = 0.$$

Esse resultado é fundamental em rotinas de **busca linear** (line search).

5 Método do declive máximo (steepest descent / Cauchy)

5.1 Ideia básica

- Em cada iteração i , escolhemos a direção

$$S_i = -\nabla f(X_i),$$

que é a direção de **máxima descida** de f a partir de X_i .

- Em seguida, realizamos uma busca unidimensional em λ para encontrar o melhor passo λ_i^* .
- Atualizamos o ponto usando $X_{i+1} = X_i + \lambda_i^* S_i$.

5.2 Algoritmo

1. **Inicialização:** escolher um ponto inicial $X_1 \in \mathbb{R}^n$ e definir $i = 1$.
2. **Direção de busca:**

$$S_i = -\nabla f(X_i).$$

3. **Busca unidimensional:** determinar o passo ótimo

$$\lambda_i^* = \arg \min_{\lambda \geq 0} f(X_i + \lambda S_i).$$

4. **Atualização do ponto:**

$$X_{i+1} = X_i + \lambda_i^* S_i = X_i - \lambda_i^* \nabla f(X_i).$$

5. **Teste de convergência:** se algum critério de parada for satisfeito, encerrar; caso contrário, definir $i \leftarrow i + 1$ e voltar ao passo 2.

Observação didática: apesar de usar a melhor direção local de descida, o método pode ser **lento** em vales estreitos (comportamento de “zigue-zague”), motivando o estudo de métodos mais avançados (Newton, quasi-Newton, gradiente conjugado, etc.).

6 Exemplo: aplicação do método do declive máximo

Considere

$$f(x_1, x_2) = x_1 - x_2 + 2x_1^2 + 2x_1x_2 + x_2^2.$$

6.1 Gradiente

$$\nabla f = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \end{bmatrix} = \begin{bmatrix} 1 + 4x_1 + 2x_2 \\ -1 + 2x_1 + 2x_2 \end{bmatrix}.$$

6.2 Iteração 1

- Ponto inicial:

$$X_1 = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

- Gradiente em X_1 :

$$\nabla f_1 = \nabla f(X_1) = \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

- Direção de descida:

$$S_1 = -\nabla f_1 = \begin{bmatrix} -1 \\ 1 \end{bmatrix}.$$

- Ponto ao longo da direção:

$$X(\lambda_1) = X_1 + \lambda_1 S_1 = (-\lambda_1, \lambda_1).$$

- Função ao longo da reta:

$$f(-\lambda_1, \lambda_1) = \lambda_1^2 - 2\lambda_1.$$

- Derivada em relação a λ_1 :

$$\frac{df}{d\lambda_1} = 2\lambda_1 - 2.$$

- Passo ótimo:

$$2\lambda_1 - 2 = 0 \Rightarrow \lambda_1^* = 1.$$

- Atualização:

$$X_2 = X_1 + \lambda_1^* S_1 = \begin{bmatrix} -1 \\ 1 \end{bmatrix}.$$

6.3 Iterações seguintes (esboço)

- **Iteração 2:** calcular ∇f_2 , S_2 , construir $f(X_2 + \lambda_2 S_2)$, encontrar λ_2^* , obter X_3 .
- **Iteração 3 e seguintes:** repetir o procedimento até satisfazer um critério de parada.
- O ponto ótimo é

$$X^* = \begin{bmatrix} -1.0 \\ 1.5 \end{bmatrix}.$$

Em sala, pode-se:

- Resolver a Iteração 2 com os alunos.
- Deixar as iterações seguintes como exercício.
- Discutir o comportamento de zigue-zague em curvas de nível.

7 Critérios de parada

Critérios usuais para encerrar o método iterativo:

7.1 Variação relativa pequena em f

$$\left| \frac{f(X_{i+1}) - f(X_i)}{f(X_i)} \right| \leq \varepsilon_1.$$

7.2 Norma do gradiente pequena

$$\left| \frac{\partial f}{\partial x_j} \right| \leq \varepsilon_2, \quad j = 1, \dots, n,$$

ou, mais compactamente,

$$\|\nabla f(X_i)\| \leq \varepsilon_2.$$

7.3 Mudança pequena em X

$$\|X_{i+1} - X_i\| \leq \varepsilon_3.$$

Na prática, usualmente combina-se mais de um critério, com tolerâncias como 10^{-3} , 10^{-4} , etc., dependendo da aplicação.

8 Encerramento e próximos passos

- Nesta aula:

- Definimos o gradiente e interpretamos seu papel como direção de **steepest ascent**.
- Vimos que $-\nabla f$ define uma direção de **steepest descent**.
- Apresentamos formas de **aproximar numericamente** o gradiente via diferenças finitas.
- Derivamos a taxa de variação de f ao longo de uma direção S_i :

$$\frac{df}{d\lambda} = \nabla f^\top S_i.$$

- Estudamos o **método do declive máximo** (Cauchy) e aplicamos a um exemplo.
- Discutimos **critérios de parada** em métodos iterativos.
- Próximas aulas:
 - Limitações do steepest descent em vales estreitos.
 - Métodos mais avançados: **Newton**, **quasi-Newton**, **gradiente conjugado**, etc.