

Roteiro de Aula – Métodos de Gradiente para Treinamento de Redes Neurais

Prof. Rodrigo Silva

1 Motivação

O treinamento de redes neurais consiste em minimizar uma função de perda

$$L(\theta),$$

onde θ representa todos os parâmetros do modelo. O gradiente pode ser calculado eficientemente via *backpropagation*, de modo que métodos baseados em gradiente são a principal ferramenta de otimização em aprendizagem profunda.

Nesta aula estudaremos os principais métodos de descida comumente utilizados no treinamento de redes neurais.

2 Gradient Descent Básico

Dado um vetor de parâmetros θ_k , a atualização por descida do gradiente é:

$$\theta_{k+1} = \theta_k - \alpha \nabla_{\theta} L(\theta_k),$$

onde $\alpha > 0$ é a taxa de aprendizado. As principais variantes práticas são:

- **Batch GD**: usa todo o conjunto de dados.
- **Stochastic GD**: usa apenas um exemplo por iteração.
- **Mini-batch GD**: usa subconjuntos dos dados (forma usual).

Limitações principais:

- sensibilidade à escolha do α ;
- pode oscilar em vales estreitos da função;
- pode convergir lentamente.

3 Gradient Descent com Momentum

O método adiciona o conceito de “velocidade” acumulada:

$$\begin{aligned} v_{k+1} &= \beta v_k + (1 - \beta) \nabla L(\theta_k), \\ \theta_{k+1} &= \theta_k - \alpha v_{k+1}, \end{aligned}$$

onde $\beta \in [0.9, 0.99]$ regula a influência do passado.

Vantagens:

- acelera o avanço em direções consistentes;
- reduz oscilações devido a ruído no gradiente.

4 AdaGrad

O AdaGrad adapta a taxa de aprendizado individualmente para cada parâmetro acumulando os quadrados dos gradientes:

$$\begin{aligned} g_{k+1} &= g_k + (\nabla L(\theta_k))^2, \\ \theta_{k+1} &= \theta_k - \frac{\alpha}{\sqrt{g_{k+1}} + \varepsilon} \nabla L(\theta_k). \end{aligned}$$

Consequências:

- parâmetros com gradientes grandes têm passo reduzido;
- parâmetros com gradientes pequenos têm passo ampliado.

Problema principal: o termo acumulado cresce monotonicamente, levando a passos cada vez menores.

5 RMSProp

RMSProp corrige o AdaGrad substituindo a soma acumulada por uma média móvel exponencial:

$$s_{k+1} = \beta s_k + (1 - \beta)(\nabla L(\theta_k))^2,$$
$$\theta_{k+1} = \theta_k - \frac{\alpha}{\sqrt{s_{k+1}} + \varepsilon} \nabla L(\theta_k).$$

Vantagens:

- evita que o passo tenda a zero;
- funciona bem com gradientes ruidosos;
- é amplamente utilizado em redes profundas.

6 RMSProp com Momentum

Combinação da média móvel adaptativa do RMSProp com o acúmulo de velocidade do momentum:

$$s_{k+1} = \beta s_k + (1 - \beta)(\nabla L(\theta_k))^2,$$
$$v_{k+1} = \mu v_k + \frac{\alpha}{\sqrt{s_{k+1}} + \varepsilon} \nabla L(\theta_k),$$
$$\theta_{k+1} = \theta_k - v_{k+1}.$$

Vantagens: maior estabilidade e aceleração.

7 AdaDelta

O AdaDelta busca eliminar a dependência direta do parâmetro α .

Acumula gradientes:

$$E[g^2]_{k+1} = \beta E[g^2]_k + (1 - \beta)(\nabla L(\theta_k))^2.$$

Define a atualização:

$$\Delta \theta_k = - \frac{\sqrt{E[\Delta \theta^2]_k + \varepsilon}}{\sqrt{E[g^2]_{k+1}} + \varepsilon} \nabla L(\theta_k).$$

Acumula as atualizações:

$$E[\Delta \theta^2]_{k+1} = \beta E[\Delta \theta^2]_k + (1 - \beta)(\Delta \theta_k)^2.$$

Benefícios:

- reduz a necessidade de escolher α ;
- acelera regiões planas e estabiliza regiões de grande curvatura.

8 Adam – Adaptive Moment Estimation

O Adam combina momentum com RMSProp e inclui correção de viés.

Momentos:

$$m_{k+1} = \beta_1 m_k + (1 - \beta_1) \nabla L(\theta_k),$$
$$v_{k+1} = \beta_2 v_k + (1 - \beta_2) (\nabla L(\theta_k))^2.$$

Correções de viés:

$$\hat{m}_{k+1} = \frac{m_{k+1}}{1 - \beta_1^{k+1}}, \quad \hat{v}_{k+1} = \frac{v_{k+1}}{1 - \beta_2^{k+1}}.$$

Atualização final:

$$\theta_{k+1} = \theta_k - \frac{\alpha \hat{m}_{k+1}}{\sqrt{\hat{v}_{k+1}} + \varepsilon}.$$

Vantagens principais:

- rápido e estável;
- altamente utilizado em aprendizagem profunda;
- adapta-se automaticamente a diferentes escalas de parâmetros.

9 Resumo Comparativo

- GD: simples, porém lento e sensível ao passo.
- Momentum: acelera e suaviza oscilações.
- AdaGrad: adapta o passo, mas pode estagnar.
- RMSProp: adapta o passo sem estagnação.
- RMSProp + Momentum: equilíbrio entre estabilidade e velocidade.
- AdaDelta: reduz dependência do α .
- Adam: método mais utilizado atualmente.