

# Lecture Notes: Newton's Method

## 1 Motivation

Newton's method is a second-order optimization technique that uses information from the gradient and the Hessian (matrix of second derivatives) of the objective function to construct a local quadratic model around the current iterate. This quadratic approximation is then minimized to obtain a new point.

The basic idea is: if the function  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  is smooth and we are at a point  $x_i$  close to a minimizer, then a quadratic Taylor approximation of  $f$  around  $x_i$  can be used to compute a search direction that points directly toward the optimum (for quadratic functions, in a single step).

## 2 Quadratic Approximation and Newton Step

### Step 1: Taylor expansion around the current point

Consider a twice continuously differentiable function  $f : \mathbb{R}^n \rightarrow \mathbb{R}$ . Around a point  $x_i$ , we can approximate  $f$  by a second-order Taylor expansion:

$$f(x) \approx f(x_i) + \nabla f_i^\top (x - x_i) + \frac{1}{2}(x - x_i)^\top H_i(x - x_i),$$

where

$$\nabla f_i := \nabla f(x_i) \quad \text{e} \quad H_i := \nabla^2 f(x_i)$$

é a matriz Hessiana avaliada em  $x_i$ .

### Step 2: Local quadratic model

Definimos o modelo quadrático local  $m_i : \mathbb{R}^n \rightarrow \mathbb{R}$  como

$$m_i(x) = f(x_i) + \nabla f_i^\top (x - x_i) + \frac{1}{2}(x - x_i)^\top H_i(x - x_i).$$

Queremos encontrar o ponto que minimiza esse modelo. Seja

$$p := x - x_i$$

o deslocamento a partir de  $x_i$ . Então

$$m_i(x_i + p) = f(x_i) + \nabla f_i^\top p + \frac{1}{2}p^\top H_i p.$$

O problema local de minimização torna-se:

$$\min_{p \in \mathbb{R}^n} q(p) := \nabla f_i^\top p + \frac{1}{2}p^\top H_i p.$$

### Step 3: Condição de otimalidade do modelo quadrático

Para minimizar  $q(p)$ , derivamos em relação a  $p$  e igualamos a zero:

$$\nabla_p q(p) = \nabla f_i + H_i p = 0.$$

Assim, a condição de primeira ordem para o mínimo do modelo é

$$H_i p = -\nabla f_i.$$

Supondo que  $H_i$  seja não singular (invertível), obtemos

$$p^* = -H_i^{-1} \nabla f_i.$$

### Step 4: Atualização de Newton

O próximo ponto  $x_{i+1}$  é obtido somando o deslocamento ótimo  $p^*$  ao ponto atual:

$$x_{i+1} = x_i + p^* = x_i - H_i^{-1} \nabla f_i.$$

Esta é a fórmula clássica do passo de Newton:

$$x_{i+1} = x_i - [\nabla^2 f(x_i)]^{-1} \nabla f(x_i).$$

Como a aproximação de Taylor truncou termos de ordem superior, essa atualização é aplicada de forma iterativa para aproximar um ponto  $x^*$  tal que  $\nabla f(x^*) = 0$ .

### 3 Geometric Interpretation

Em uma dimensão ( $n = 1$ ), Newton para encontrar raízes de  $f'(x) = 0$  interpreta-se como:

- A reta tangente ao gráfico de  $f'(x)$  em  $x_i$  é usada para encontrar o próximo ponto onde a derivada se anula.
- Em múltiplas dimensões, o mesmo raciocínio é generalizado usando o gradiente  $\nabla f$  e a Hessiana  $\nabla^2 f$  para determinar o deslocamento  $p^*$  que anula o gradiente do modelo quadrático.

Quando  $x_i$  está suficientemente próximo de um mínimo estrito e  $H_i$  é definida positiva, o método apresenta convergência quadrática.

### 4 Newton's Method Algorithm (Basic Version)

We summarize the basic Newton method for unconstrained minimization.

1. Choose an initial guess  $x_1$ .
2. For  $i = 1, 2, \dots$ :
  - (a) Compute the gradient and Hessian at  $x_i$ :

$$\nabla f_i = \nabla f(x_i), \quad H_i = \nabla^2 f(x_i).$$

- (b) Solve the linear system

$$H_i p_i = -\nabla f_i$$

for the Newton step  $p_i$ .

- (c) Update

$$x_{i+1} = x_i + p_i.$$

- (d) If  $\|\nabla f_{i+1}\|$  is sufficiently small, stop.

### 5 Special Case: Quadratic Functions

Considere uma função quadrática geral

$$f(x) = \frac{1}{2}x^\top Ax + b^\top x + c,$$

onde  $A$  é uma matriz simétrica definida positiva. Então:

$$\nabla f(x) = Ax + b, \quad \nabla^2 f(x) = A.$$

O ponto de mínimo é dado por

$$\nabla f(x^*) = 0 \implies Ax^* + b = 0 \implies x^* = -A^{-1}b.$$

O passo de Newton, em qualquer iteração  $i$ , é

$$x_{i+1} = x_i - A^{-1}(Ax_i + b) = x_i - A^{-1}Ax_i - A^{-1}b = -A^{-1}b = x^*.$$

Ou seja, para funções quadráticas com Hessiana constante  $A$ , o método de Newton encontra o ponto ótimo em *uma única iteração* (independentemente de  $x_1$ ), desde que  $A$  seja não singular.

### 6 Example: Minimization of a Quadratic Function

Considere a função

$$f(x_1, x_2) = x_1 - x_2 + 2x_1^2 + 2x_1x_2 + x_2^2,$$

com ponto inicial

$$x_1 = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

#### Step 1: Gradient and Hessian

O gradiente é

$$\nabla f(x_1, x_2) = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \end{bmatrix} = \begin{bmatrix} 1 + 4x_1 + 2x_2 \\ -1 + 2x_1 + 2x_2 \end{bmatrix}.$$

O Hessiano (constante) é

$$\nabla^2 f(x) = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} \end{bmatrix} = \begin{bmatrix} 4 & 2 \\ 2 & 2 \end{bmatrix} = H.$$

### Step 2: Evaluate at the initial point

No ponto inicial  $x_1 = (0, 0)^\top$ ,

$$\nabla f_1 = \nabla f(0, 0) = \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

### Step 3: Compute the Newton step

Precisamos de  $H^{-1}$ . Como

$$H = \begin{bmatrix} 4 & 2 \\ 2 & 2 \end{bmatrix},$$

uma inversa possível é

$$H^{-1} = \begin{bmatrix} \frac{1}{2} & -\frac{1}{2} \\ -\frac{1}{2} & 1 \end{bmatrix}.$$

O passo de Newton é

$$p_1 = -H^{-1}\nabla f_1 = -\begin{bmatrix} \frac{1}{2} & -\frac{1}{2} \\ -\frac{1}{2} & 1 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \end{bmatrix} = -\begin{bmatrix} \frac{1}{2}(1) + (-\frac{1}{2})(-1) \\ -\frac{1}{2}(1) + 1(-1) \end{bmatrix} = -\begin{bmatrix} 1 \\ -\frac{3}{2} \end{bmatrix} = \begin{bmatrix} -1 \\ \frac{3}{2} \end{bmatrix}.$$

### Step 4: Update the point

$$x_2 = x_1 + p_1 = \begin{bmatrix} 0 \\ 0 \end{bmatrix} + \begin{bmatrix} -1 \\ \frac{3}{2} \end{bmatrix} = \begin{bmatrix} -1 \\ \frac{3}{2} \end{bmatrix}.$$

### Step 5: Check optimality

Calculamos o gradiente em  $x_2$ :

$$\nabla f_2 = \nabla f(-1, \frac{3}{2}) = \begin{bmatrix} 1 + 4(-1) + 2(\frac{3}{2}) \\ -1 + 2(-1) + 2(\frac{3}{2}) \end{bmatrix} = \begin{bmatrix} 1 - 4 + 3 \\ -1 - 2 + 3 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

Logo,  $\nabla f_2 = 0$  e  $x_2$  é o ponto ótimo. Como esperado para uma função quadrática, o método de Newton convergiu em uma única iteração.

## 7 Newton's Method with Line Search

Na prática, para funções não quadráticas, o passo

$$x_{i+1} = x_i - H_i^{-1}\nabla f_i$$

pode não ser adequado:

- o método pode divergir;
- pode convergir para um ponto de sela ou máximo;
- o tamanho do passo pode ser muito grande ou muito pequeno.

Uma modificação comum é introduzir um *line search* na direção de Newton:

$$s_i = -H_i^{-1}\nabla f_i,$$

$$x_{i+1} = x_i + \lambda_i^* s_i,$$

onde  $\lambda_i^*$  é um passo que tenta minimizar  $f(x_i + \lambda s_i)$  em relação a  $\lambda$  (por exemplo, satisfazendo condições de Wolfe). Isso leva ao *método de Newton com busca linear*, que em geral é mais robusto e evita convergência para pontos indesejáveis.

## 8 Weaknesses of Newton's Method

Apesar de suas boas propriedades teóricas (convergência quadrática próxima ao ótimo, convergência em um passo para funções quadráticas), o método de Newton tem limitações práticas importantes.

### Cálculo e armazenamento da Hessiana

O método requer a matriz Hessiana  $H_i = \nabla^2 f(x_i)$ :

- Para problemas de dimensão  $n$ ,  $H_i$  é uma matriz  $n \times n$ , com  $O(n^2)$  elementos.
- Em muitos problemas práticos (como em aprendizado de máquina com milhares ou milhões de parâmetros), é inviável calcular e armazenar explicitamente a Hessiana.

## Custo de inversão / solução de sistemas lineares

A cada iteração é necessário resolver

$$H_i p_i = -\nabla f_i.$$

Mesmo usando métodos numéricos eficientes, o custo típico é  $O(n^3)$  em tempo para inversão direta ou fatorações, o que se torna proibitivo em alta dimensão.

## Dificuldade em obter derivadas de segunda ordem

Para funções complicadas, a expressão analítica de  $\nabla^2 f(x)$  pode ser:

- difícil de derivar manualmente;
- sujeita a erros de implementação;
- custosa de avaliar numericamente.

Técnicas como diferenciação automática ajudam, mas ainda há custo de memória e tempo consideráveis.

## Sensibilidade e não convergência em funções não quadráticas

Em funções não quadráticas:

- a Hessiana pode não ser definida positiva em toda a região de interesse;
- o método pode divergir se o ponto inicial não estiver suficientemente próximo do mínimo;
- o método pode convergir para pontos de sela ou máximos se não houver controle adicional (por exemplo, via modificações da Hessiana ou line search adequado).

## 9 Por que o Método de Newton Pode Divergir?

Apesar de suas excelentes propriedades teóricas — incluindo convergência quadrática e obtenção do minimizador em uma única iteração no caso quadrático — o método de Newton pode divergir de forma severa quando aplicado a funções não quadráticas, quando o ponto inicial está longe do ótimo ou quando a Hessiana não é definida positiva. Nesta seção discutimos, de maneira detalhada, as causas mais comuns de divergência.

### 1. A Hessiana pode não ser definida positiva

O passo de Newton é obtido resolvendo

$$H_i p_i = -\nabla f_i,$$

onde  $H_i = \nabla^2 f(x_i)$ .

Se a Hessiana for indefinida (isto é, contiver autovalores positivos e negativos), então a direção  $p_i$  pode apontar para uma direção de *subida*, não de descida. Mais ainda:

- se  $H_i$  tem autovalores negativos, Newton pode mover o ponto em direção a máximos locais;
- se  $H_i$  é indefinida, Newton mistura direções de subida e descida, gerando comportamento altamente instável.

**Exemplo:** A função sela

$$f(x, y) = x^2 - y^2$$

possui Hessiana

$$H = \begin{bmatrix} 2 & 0 \\ 0 & -2 \end{bmatrix},$$

com um autovalor positivo e um negativo. O método de Newton leva a quedas ao longo da direção  $x$  e disparos divergentes ao longo da direção  $y$ . Assim,  $x_i$  tende ao mínimo enquanto  $y_i$  diverge para  $\pm\infty$ , tornando o método praticamente inútil nesse caso.

### 2. A aproximação quadrática pode ser ruim longe do ótimo

Newton supõe que  $f$  é bem aproximada localmente por uma função quadrática:

$$f(x) \approx f(x_i) + \nabla f_i^\top (x - x_i) + \frac{1}{2}(x - x_i)^\top H_i (x - x_i).$$

Quando  $x_i$  está longe do ótimo, esta aproximação pode ser extremamente ruim, fazendo com que o passo de Newton seja exagerado. O resultado pode ser:

- saltos grandes que saem da região de interesse;
- oscilações entre regiões distantes;
- *overshooting*, em que o método “passa direto” pelo vale;

- divergência numérica.

**Exemplo:** A função  $f(x) = \sqrt{x}$  (definida em  $x > 0$ ) produz passos de Newton que estouram rapidamente e podem sair do domínio da função.

### 3. O método pode convergir para pontos de sela ou máximos

Newton procura resolver  $\nabla f = 0$ , mas não distingue entre tipos de pontos críticos. Assim, ele pode facilmente convergir para:

- máximos locais (onde  $H$  é definida negativa),
- pontos de sela (onde  $H$  é indefinida),
- pontos estacionários degenerados.

**Exemplo ilustrativo:**

$$f(x) = x^3.$$

Seu único ponto crítico é  $x = 0$ , que é um ponto de sela. No entanto, Newton gera:

$$x_{i+1} = x_i - \frac{3x_i^2}{6x_i} = \frac{x_i}{2},$$

convergindo para 0, interpretando-o erroneamente como solução aceitável.

### 4. Segunda derivada pequena pode gerar passos catastróficos

Em uma dimensão, Newton usa:

$$x_{i+1} = x_i - \frac{f'(x_i)}{f''(x_i)}.$$

Se  $f''(x_i)$  é muito pequeno, então o denominador torna o passo extremamente grande, lançando o método muito longe do ótimo. Esse é um dos mecanismos mais comuns de divergência em funções suaves, mas relativamente planas.

### 5. O próximo ponto pode sair do domínio da função

Quando a função é restrita a um domínio especial (por exemplo,  $x > 0$  em  $f(x) = \ln x$ ), Newton pode gerar  $x_{i+1}$  fora do domínio e tornar o processo inviável.

**Exemplo:**

$$f(x) = \ln(x), \quad x > 0.$$

Newton produz:

$$x_{i+1} = 2x_i,$$

que pode facilmente sair da região em que a função é bem comportada, levando a valores inválidos ou divergentes.

### 6. Sensibilidade extrema ao ponto inicial

Newton só é garantidamente eficiente quando  $x_1$  está suficientemente próximo do ótimo. Se o ponto inicial estiver longe:

- a aproximação quadrática é incorreta;
- a Hessiana pode ter sinal errado;
- as derivações sucessivas podem magnificar erros.

Esse comportamento explica por que, na prática, usa-se:

- line search (Newton amortecido),
- métodos de região de confiança,
- Hessianas modificadas para garantir positividade.

## Resumo

O método de Newton pode divergir devido a:

- Hessianas indefinidas ou negativas,
- más aproximações quadráticas longe do ótimo,
- passos muito grandes quando  $f''(x)$  é pequeno,
- convergência para pontos de sela,
- saída do domínio da função,

- alta sensibilidade ao ponto inicial.

Quando utilizado sem salvaguardas, o método pode apresentar comportamento oscilatório ou mesmo explodir numericamente. A inclusão de uma busca linear ou de uma região de confiança corrige a maior parte desses problemas, tornando o método de Newton mais estável e aplicável em larga escala.

## Resumo

O método de Newton é muito eficiente quando:

- $f$  é bem aproximada localmente por uma função quadrática;
- a Hessiana é definida positiva e não muda radicalmente;
- o custo de computar e manipular a Hessiana é aceitável.

Em problemas de grande escala ou com funções muito não lineares, essas condições raramente são satisfeitas, motivando variantes como métodos quasi-Newton (BFGS, L-BFGS) e métodos baseados apenas em primeira ordem.

## 10 Conclusion

Newton's method uses second-order information to build a local quadratic model of the objective function and update the iterate by solving a linear system involving the Hessian. For quadratic functions, it reaches the minimum in a single iteration. For general nonlinear functions, it can exhibit fast (quadratic) convergence near a local minimizer, but its practical use is limited by:

- the cost of computing and storing the Hessian;
- the need to solve large linear systems;
- potential divergence or convergence to saddle points without safeguards.

These limitations motivate many modern variants that trade off exact second-order information for cheaper approximations, preserving some of Newton's advantages while remaining computationally feasible.